# Московский государственный технический университет им. Н.Э. Баумана Факультет «Информатика и системы управления» Кафедра «Системы обработки информации и управления»



# **Лабораторная работа №2** по курсу «Методы машинного обучения»

«Обработка признаков (часть 1)»

|   |   | Андронов Д.О.  |  |  |  |  |
|---|---|----------------|--|--|--|--|
|   |   | Группа ИУ5-24М |  |  |  |  |
| " | " | 2022 г         |  |  |  |  |

ИСПОЛНИТЕЛЬ:

# Цель работы:

Изучение продвинутых способов предварительной обработки данных для дальнейшего формирования моделей.

#### Задание:

Выбрать набор данных (датасет), содержащий категориальные и числовые признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.) Просьба не использовать датасет, на котором данная задача решалась в лекции. Для выбранного датасета (датасетов) на основе материалов лекций решить следующие задачи:

- устранение пропусков в данных;
- кодирование категориальных признаков;
- нормализацию числовых признаков.

#### Выполнение:

### Устранение пропусков в данных

```
In [2]:
         data = pd.read_csv('top_100_movies_by_genres.csv', sep=",")
In [3]: data.shape
Out[3]: (1612, 5)
In [4]: data.dtypes
                              object
float64
Out[4]: Genre
        {\tt RatingTomatometer}
                               object
        Title
No. of Reviews
dtype: object
                               object
In [5]: data.head()
Out[5]:
                      Genre Rank RatingTomatometer
        0 Action & Adventure
                                                                    Black Panther (2018)
                                           94%
                                                                                              547
        1 Action & Adventure 2.0
                                                               Avengers: Endgame (2019)
        2 Action & Adventure 3.0
                                      97%
                                                        Mission: Impossible - Fallout (2018)
                                                                                              437
                                      97%
        3 Action & Adventure 4.0
                                                              Mad Max: Fury Road (2015)
                                   97% Spider-Man: Into the Spider-Verse (2018)
        4 Action & Adventure 5.0
 In [6]:
          def get_loss(some_data):
               for col in some_data.columns:
    null_counter = some_data[some_data[col].isnull()].shape[0]
                   print("{} : {}".format(col,null_counter))
```

```
In [39]: # % пропусков
          [(c, data2[c].isnull().mean()) for c in data2]
In [40]: array_to_del = ['Genre','Title']
In [42]:
          [(c, new_data[c].isnull().mean()) for c in new_data]
In [46]:
          def impute_na(df, variable, value):
              df[variable].fillna(value, inplace=True)
          impute_na(new_data, 'RatingTomatometer', new_data['RatingTomatometer'].mean())
impute_na(new_data, 'No. of Reviews', new_data['No. of Reviews'].mean())
impute_na(new_data, 'Rank', new_data['Rank'].mean())
         c:\users\s4lly\pycharmprojects\lab1\venv\lib\site-packages\pandas\core\series.py:4536: SettingWithCopyWarning: A value is trying to be set on a copy of a slice from a DataFrame
          See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#ret
          urning-a-view-versus-a-copy
          downcast=downcast,
In [47]: get_loss(new_data)
          Genre: 0
          Rank: 0
          RatingTomatometer : 0
          Title : 0
          No. of Reviews : 0
```

# Кодирование категориальных признаков

| [51]:   | <pre># one-hot pd.get_dummies(new_data2[['Genre']]).head()</pre> |                             |                 |                                       |                |              |                   |             |              |
|---------|--|-----------------------------|-----------------|---------------------------------------|----------------|--------------|-------------------|-------------|--------------|
| rt[51]: |  | Genre_Action<br>& Adventure | Genre_Animation | Genre_Art<br>House &<br>International | Genre_Classics | Genre_Comedy | Genre_Documentary | Genre_Drama | Genre_Horror |
|         | 0  | 1                           | 0               | 0                                     | 0              | 0            | 0                 | 0           | 0            |
|         | 1  | 1                           | 0               | 0                                     | 0              | 0            | 0                 | 0           | 0            |
|         | 3  | 1                           | 0               | 0                                     | 0              | 0            | 0                 | 0           | 0            |
|         | 4  | 1                           | 0               | 0                                     | 0              | 0            | 0                 | 0           | 0            |
|         | 5  | 1                           | 0               | 0                                     | 0              | 0            | 0                 | 0           | 0            |
|         | 4  |                             |                 |                                       |                |              |                   |             | <b>+</b>     |

```
In [62]: # Count (frequency) encoding
import category_encoders as ce
new_data3 = new_data.copy()
data_OHE = new_data.copy()
ce_CountEncoder1 = ce.CountEncoder()
data_OHE[['Genre']] = ce_CountEncoder1.fit_transform(new_data3['Genre'])
data_OHE
Out[62]: Genre Rank RatingTomatometer Title No. of Reviews
```

| 62]: | Genre |    | Rank      | Rating Tomatometer | Title                                    | No. of Reviews |  |
|------|-------|----|-----------|--------------------|--|----------------|--|
|      | 0     | 75 | 1.000000  | 96.000000          | Black Panther (2018)                     | 525.000000     |  |
|      | 1     | 75 | 2.000000  | 94.000000          | Avengers: Endgame (2019)                 | 547.000000     |  |
|      | 3     | 75 | 4.000000  | 97.000000          | Mad Max: Fury Road (2015)                | 434.000000     |  |
|      | 4     | 75 | 5.000000  | 97.000000          | Spider-Man: Into the Spider-Verse (2018) | 393.000000     |  |
|      | 5     | 75 | 6.000000  | 92.196755          | Wonder Woman (2017)                      | 148.551339     |  |
|      |       |    |           |                    |  |                |  |
|      | 1606  | 65 | 81.000000 | 17.000000          | Wild Wild West (1999)                    | 132.000000     |  |
|      | 1608  | 65 | 48.680995 | 16.000000          | September Dawn (2007)                    | 148.551339     |  |
|      | 1609  | 65 | 84.000000 | 14.000000          | American Outlaws (2001)                  | 103.000000     |  |
|      | 1610  | 65 | 85.000000 | 12.000000          | Jonah Hex (2010)                         | 153.000000     |  |
|      | 1611  | 65 | 86.000000 | 2.000000           | Texas Rangers (2001)                     | 51.000000      |  |

1071 rows × 5 columns

| Out[64]: |      | Genre    | Rank      | RatingTomatometer | Title                                    | No. of Reviews |
|----------|------|----------|-----------|-------------------|--|----------------|
|          | 0    | 0.070028 | 1.000000  | 96.000000         | Black Panther (2018)                     | 525.000000     |
|          | 1    | 0.070028 | 2.000000  | 94.000000         | Avengers: Endgame (2019)                 | 547.000000     |
|          | 3    | 0.070028 | 4.000000  | 97.000000         | Mad Max: Fury Road (2015)                | 434.000000     |
|          | 4    | 0.070028 | 5.000000  | 97.000000         | Spider-Man: Into the Spider-Verse (2018) | 393.000000     |
|          | 5    | 0.070028 | 6.000000  | 92.196755         | Wonder Woman (2017)                      | 148.551339     |
|          |      |          |           |                   | ***                                      |                |
|          | 1606 | 0.060691 | 81.000000 | 17.000000         | Wild Wild West (1999)                    | 132.000000     |
|          | 1608 | 0.060691 | 48.680995 | 16.000000         | September Dawn (2007)                    | 148.551339     |
|          | 1609 | 0.060691 | 84.000000 | 14.000000         | American Outlaws (2001)                  | 103.000000     |
|          | 1610 | 0.060691 | 85.000000 | 12.000000         | Jonah Hex (2010)                         | 153.000000     |
|          | 1611 | 0.060691 | 86.000000 | 2.000000          | Texas Rangers (2001)                     | 51.000000      |


1071 rows × 5 columns


```
In [70]:
           # Target (Mean) encoding
            # На самом деле этот метод реализует Mean encoding
            from category_encoders import TargetEncoder
            data_MEAN_ENC = new_data.copy()
ce_TargetEncoder1 = TargetEncoder()
            data_MEAN_ENC['Genre'] = ce_TargetEncoder1.fit_transform(new_data['Genre'], new_data['RatingTomatometer'])
            data_MEAN_ENC
Out[70]:
                    Genre
                                Rank RatingTomatometer
                                                                                         Title No. of Reviews
              0 94.338364
                             1.000000
                                                96.000000
                                                                                                   525.000000
                                                                            Black Panther (2018)
                                                                                                   547.000000
              1 94.338364
                             2.000000
                                                94.000000
                                                                       Avengers: Endgame (2019)
              3 94.338364
                             4.000000
                                                97.000000
                                                                      Mad Max: Fury Road (2015)
                                                                                                   434.000000
              4 94.338364
                             5.000000
                                                97.000000 Spider-Man: Into the Spider-Verse (2018)
                                                                                                   393.000000
              5 94.338364
                             6.000000
                                                92.196755
                                                                          Wonder Woman (2017)
                                                                                                    148.551339
           1606 67.892058 81.000000
                                                17.000000
                                                                          Wild Wild West (1999)
                                                                                                   132,000000
           1608 67.892058 48.680995
                                                16.000000
                                                                         September Dawn (2007)
                                                                                                   148.551339
           1609 67.892058 84.000000
                                                14.000000
                                                                        American Outlaws (2001)
                                                                                                    103.000000
           1610 67.892058 85.000000
                                                                                                   153.000000
                                                12.000000
                                                                               Jonah Hex (2010)
           1611 67.892058 86.000000
                                                                                                    51.000000
                                                 2.000000
                                                                            Texas Rangers (2001)
```

# Нормализацию числовых признаков


```
In [31]:
    def diagnostic_plots(df, variable):
        plt.figure(figsize=(15,6))
        # zucmozpawma
        plt.subplot(1, 2, 1)
        df[variable].hist(bins=30)
        ## Q-Q plot
        plt.subplot(1, 2, 2)
        stats.probplot(df[variable], dist="norm", plot=plt)
        plt.show()
```

```
# логарифмическое
data['fixed acidity_log'] = np.log(data['fixed acidity'])
diagnostic_plots(data, 'fixed acidity_log')
```







```
# обратное
data['fixed acidity_reciprocal'] = 1 / (data['fixed acidity'])
diagnostic_plots(data, 'fixed acidity_reciprocal')
```




```
# корень вадратный data['fixed acidity']**(1/2) diagnostic_plots(data, 'fixed acidity_sqr')
```





```
# возведение в степень
data['fixed acidity_exp1'] = data['fixed acidity']**(1.5)
diagnostic_plots(data, 'fixed acidity_exp1')
                                                                                                                                                        Probability Plot
                                                                                                               60
150
125
                                                                                                               40
100
                                                                                                           Ordered 30
 75
                                                                                                               20
 50
                                                                                                               10
 25
data['fixed acidity_exp2'] = data['fixed acidity']**(0.3)
diagnostic_plots(data, 'fixed acidity_exp2')
                                                                                                                                                        Probability Plot
120
                                                                                                               23 -
                                                                                                               2.2
100
 80
                                                                                                          Ordered Values
 40
```



# Вывод:

В результате работы были изучены способы предварительной обработки данных для дальнейшего формирования моделей.